Universidad del Valle de Guatemala

Facultad de Ingeniería

Departamento de Ciencias de la Computación

[CC3084] Data Science

Laboratorio 1: Series de Tiempo

Integrante	Carné
Cristian Túnchez	231359
Nadissa Vela	23764

Contexto y Objetivo del Análisis

Este informe analiza el ingreso mensual de viajeros internacionales a Guatemala entre enero de 2009 y junio de 2026 (210 meses), a partir del registro migratorio proporcionado (161,036 filas). El objetivo es caracterizar el comportamiento histórico del turismo receptor, construir y comparar modelos de pronóstico (ARIMA estacional, Holt-Winters, suavizamiento exponencial simple, *seasonal naive* y Prophet) para la serie total y para sus principales regiones y fronteras de entrada, y traducir los resultados en hallazgos accionables para INGUAT.

En todo el informe se usa la vista Turista + Excursionista, es la única categoría de viajero que se mantiene homogénea durante los 210 meses. La categoría “Viajero” cambia de definición entre 2022 y 2023, y 2026 solo tiene datos hasta junio, por lo que no es comparable con años completos.

Datos y Decisiones Metodológicas

Calidad de los datos y rupturas estructurales

El conjunto de datos no tiene valores nulos ni filas duplicadas exactas. Se corrigieron 13 grupos de duplicados por mayúsculas/minúsculas en la columna País (pasamos de contabilizar 235 países a 222 países) y se documentaron categorías residuales (valores como “0” o “SIN ESPECIFICAR”, casi todos asociados a cruceristas) que en conjunto afectan menos del 0.15% de las filas y no distorsionan el análisis.

Hallazgo principal: dos rupturas estructurales condicionan todo el modelado posterior. La primera es el colapso pandémico (2020–2021), un evento atípico que ningún modelo de tendencia y estacionalidad puede anticipar. La segunda es el cambio de metodología de reporte por país en 2022 a 2023 (de país individual a agrupaciones de mercado), que puede simular una caída de turismo donde en realidad solo cambió la forma de clasificar los datos. Ambas rupturas son la razón por la que el desempeño de los modelos, evaluado más adelante, debe leerse en términos comparativos y no como precisión absoluta.

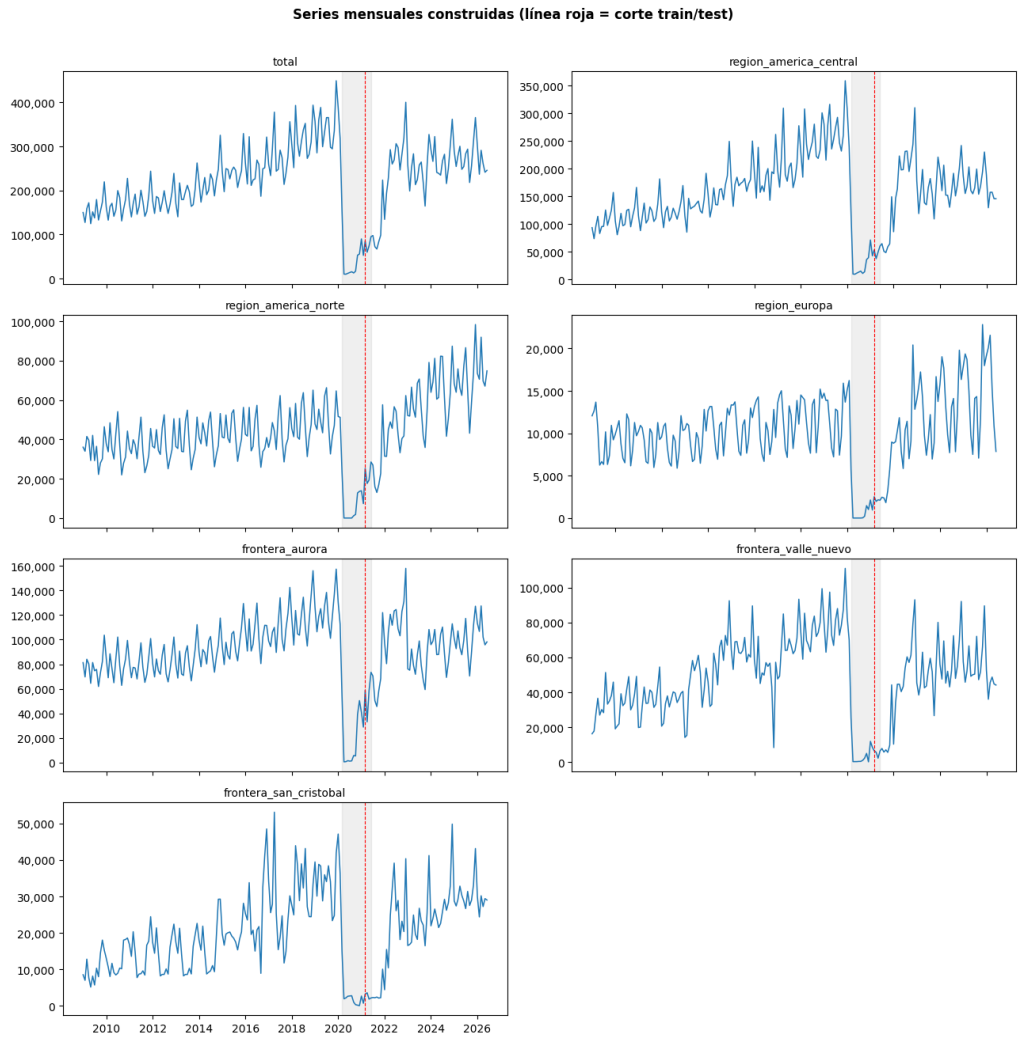
Partición entrenamiento/prueba y selección de series

La partición se hizo de forma cronológica por meses, separando 147 meses de entrenamiento (2009-01 a 2021-03, 70%) y 63 meses de prueba (2021-04 a 2026-06, 30%). El conjunto de prueba es exigente porque incluye tanto la recuperación post pandemia como el cambio de metodología de 2022–2023.

Además de la serie total obligatoria, se construyeron seis series adicionales en las dos categorías con cobertura completa (210/210 meses sin huecos): la primera, Regiones

geográficas (Centroamérica, América del Norte y Europa) y Fronteras (01 La Aurora, 07 Valle Nuevo y 09 San Cristóbal), ambas top-3 por volumen acumulado. Se descartó “País” por la ruptura de granularidad de 2023 y “Vías de ingreso” porque la vía Marítima no tiene datos desde 2017 (114 meses consecutivos faltantes). En América del Norte y Europa, los únicos huecos reales (desde abril a agosto de 2020, el cierre total de fronteras) se completaron con cero, ya que corresponden a un cierre documentado y no a un vacío de captura de datos.

***Figura 1**. Las 7 series mensuales (2009-2026) construidas para el análisis*

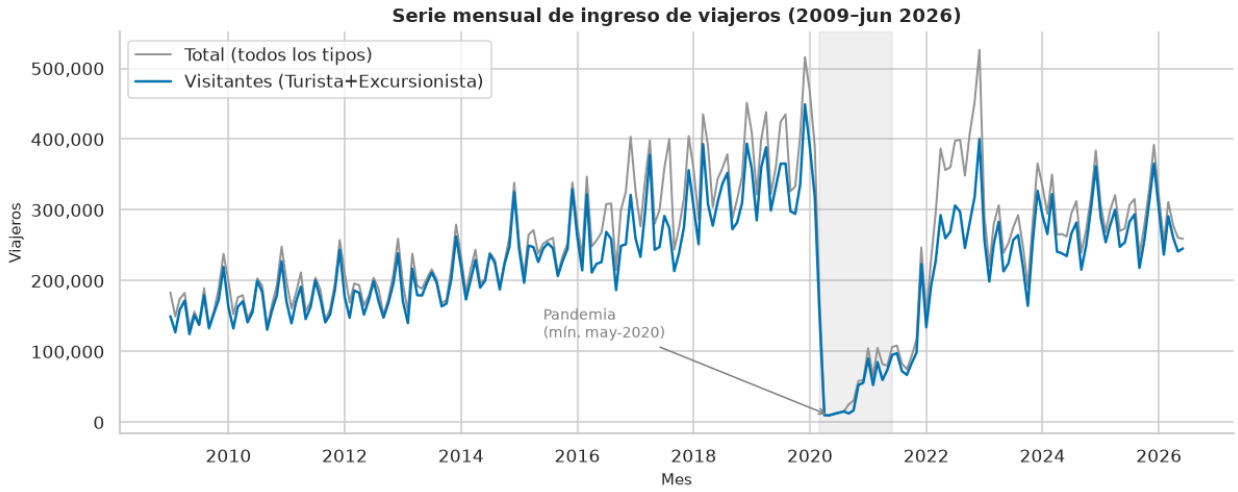


Las siete series comparten la misma forma general, un crecimiento hasta 2019, colapso pandémico y recuperación posterior a dicho suceso, porque todas son subconjuntos del mismo fenómeno migratorio, pero difieren claramente en escala, en la velocidad de recuperación y en la fuerza de su estacionalidad. Esta vista conjunta confirma que ninguna serie puede tratarse como un caso aislad. La serie total es la suma de estos comportamientos regionales y fronterizos, y esa es la relación que se cuantifica y compara en las últimas secciones del informe.

Comportamiento Histórico del Turismo Hacia Guatemala

Evolución mensual y estacionalidad

***Figura 2**. Ingreso mensual de viajeros, 2009–2026*

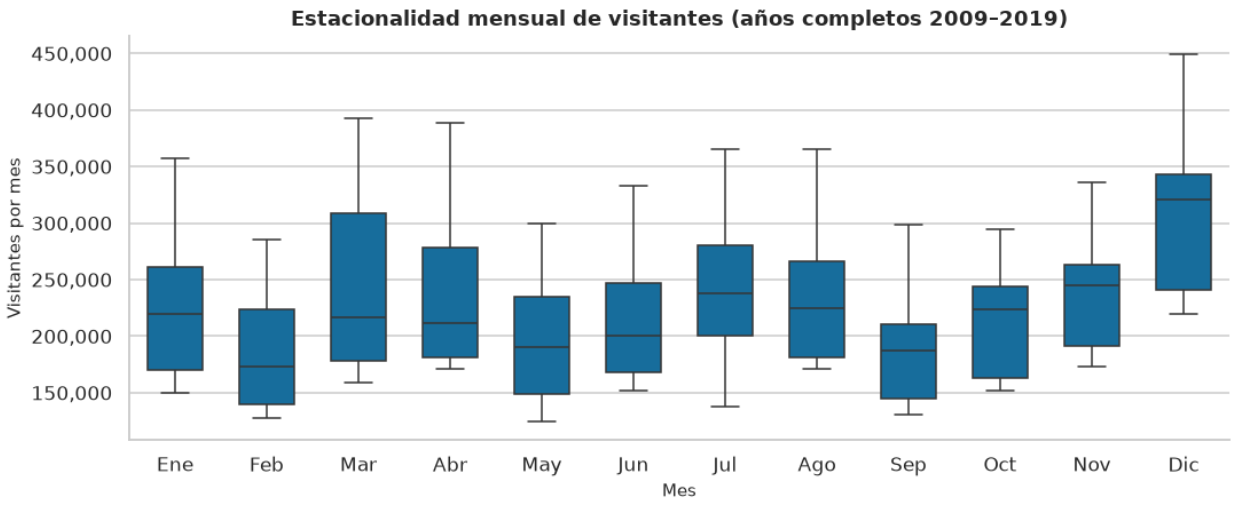


El flujo mensual de viajeros crece de forma sostenida entre 2009 y 2019, colapsa abruptamente con la pandemia y se recupera desde 2022 sin alcanzar todavía el nivel máximo histórico. La serie muestra además una estacionalidad anual muy marcada, con diciembre como mes pico (el máximo mensual absoluto fue diciembre de 2019, con

449,114 viajeros) y febrero como valle en prácticamente todos los años fuera de la pandemia.

Esta gráfica es la base de todo el análisis posterior, confirma que cualquier modelo debe capturar a la vez una tendencia de mediano plazo y un patrón estacional de periodo 12, y que la pandemia debe tratarse como una ruptura aparte, no como parte del ciclo regular. Para INGUAT, el patrón estacional permite anticipar con meses de antelación las necesidades de capacidad en temporada alta.

***Figura 3**. Total de visitantes por año.*

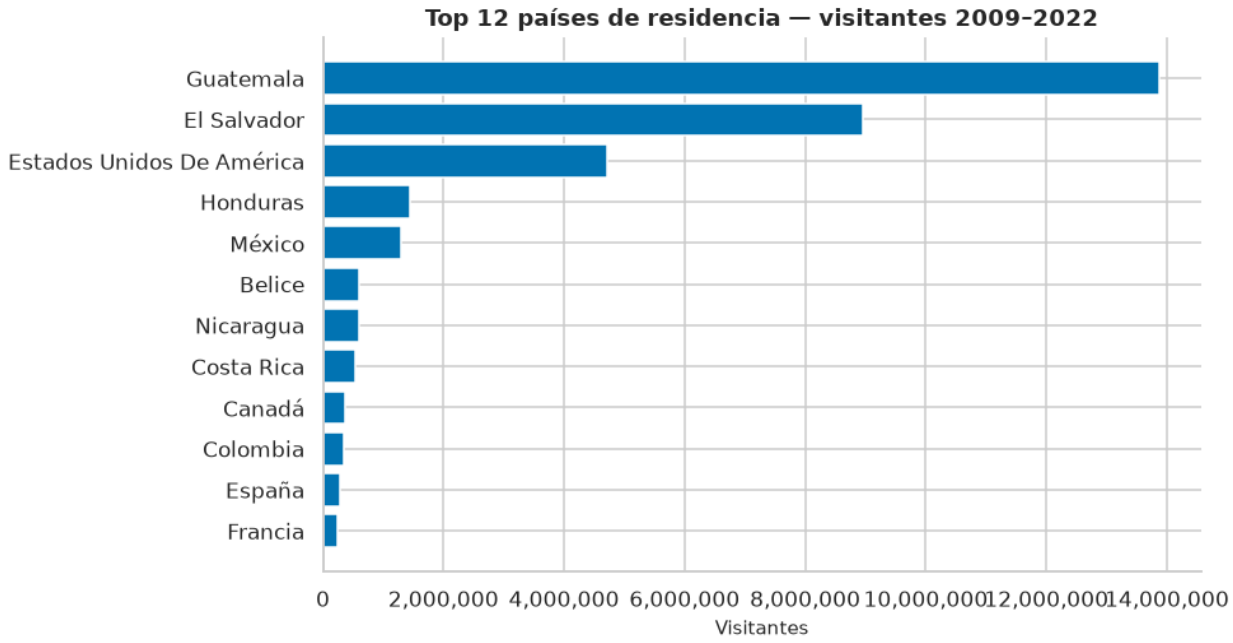


Con esta gráfica observamos que 2019 registra el máximo histórico con 4.13 millones de visitantes; 2020 cae a 1.06 millones (−74%) y 2021 se mantiene en ese mismo piso. La recuperación iniciada en 2022 (3.23 millones) se ha estabilizado alrededor de 3.3 millones en 2024–2025, todavía por debajo del pico de 2019, mientras que el mínimo mensual absoluto de toda la serie fue mayo de 2020, con apenas 9,779 viajeros. El año 2026 (1.58 millones hasta junio) es parcial y no debe compararse con años completos. Este gráfico

traduce el colapso y la recuperación post pandemia a una magnitud anual fácil de comunicar, y deja claro que, aún después de seis años, el turismo hacia Guatemala aún no se recupera por completo.

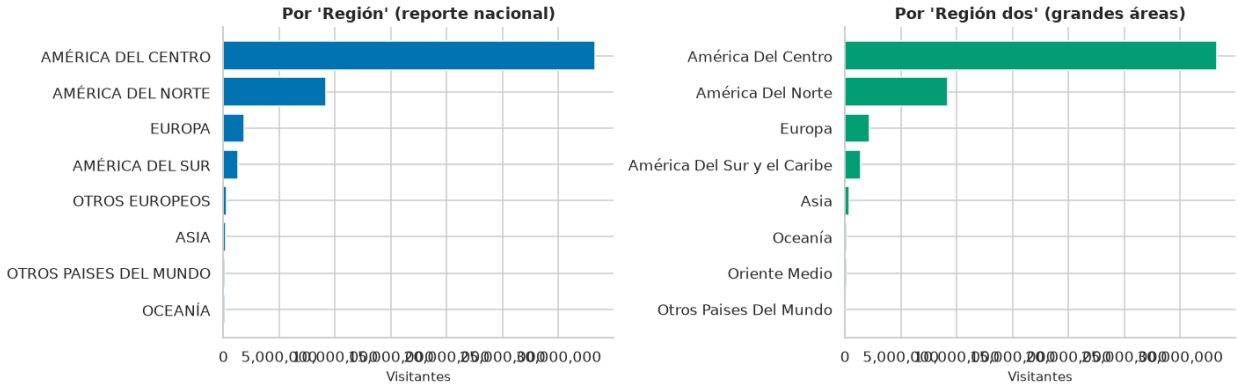
Origen, vías de acceso y concentración geográfica

***Figura 4**. Principales países de origen, 2009–2022*



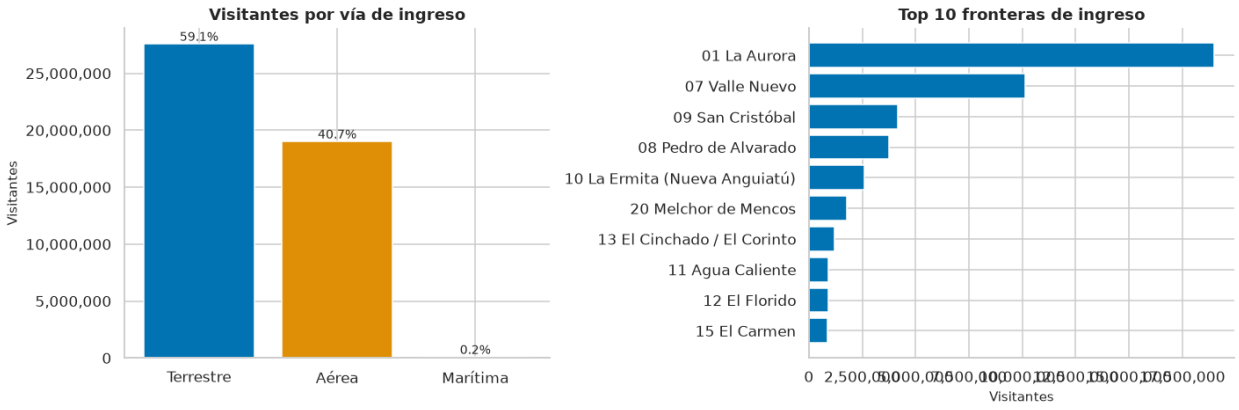
Entre 2009 y 2022, Guatemala, El Salvador y Estados Unidos concentran el 77.4% de los visitantes, mientras los mercados europeos aparecen muy por debajo. Desde 2023 el reporte cambia a agrupaciones de mercado y el liderazgo se mantiene en El Salvador, Estados Unidos y Honduras. Esta concentración es clave para priorizar recursos, cualquier política de promoción turística o de infraestructura migratoria tiene mayor impacto marginal si se enfoca primero en estos mercados, en lugar de repartirse uniformemente entre todos los países de origen.

***Figura 5**. Visitantes acumulados por región, 2009–2026*



Centroamérica concentra el 71% del total histórico de visitantes (33.28 millones), muy por encima de América del Norte (9.16 millones) y Europa (2.15 millones). La distancia entre la primera región y el resto confirma que el turismo hacia Guatemala es, ante todo, un fenómeno de movilidad regional y no un mercado internacional diversificado; esta jerarquía es la que más adelante determina qué series se modelan en detalle.

***Figura 6**. Distribución por vía de ingreso y principales fronteras*



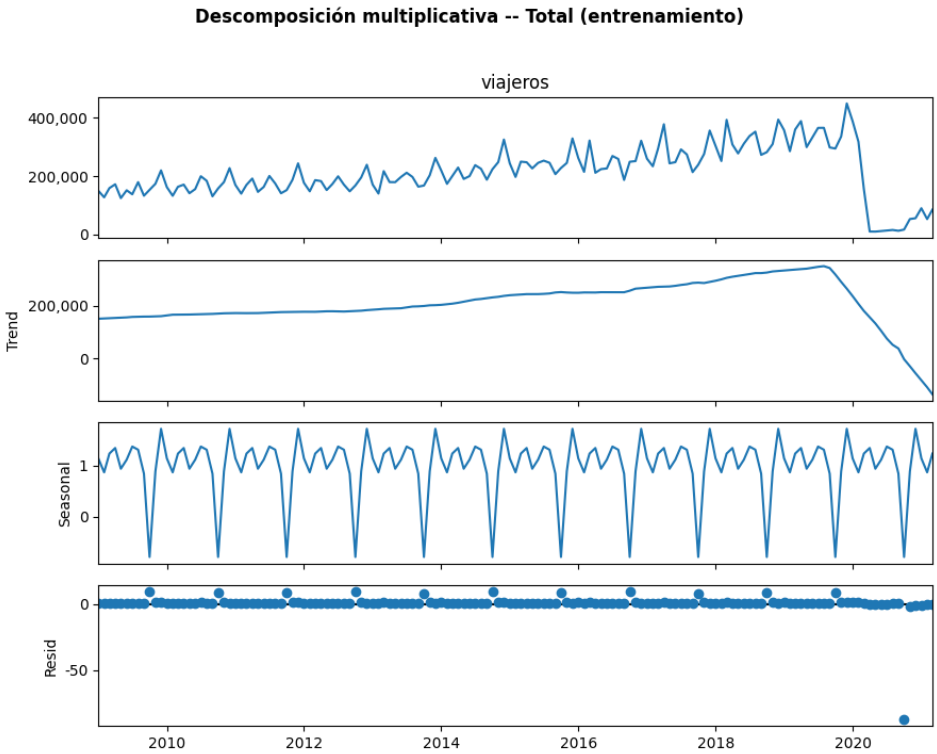
El 59.1% de los visitantes ingresa por vía terrestre y el 40.7% por vía aérea; la vía marítima es marginal (0.2%) y además dejó de reportarse en detalle desde 2017. Entre los pasos fronterizos, La Aurora (aeropuerto internacional) concentra el mayor volumen

histórico (19.0 millones), seguida de Valle Nuevo (10.1 millones, frontera con El Salvador) y San Cristóbal (4.2 millones, frontera con Honduras). Este resultado explica por qué el informe modela estas tres fronteras en detalle y descarta la categoría Vías de ingreso, cuya cobertura incompleta la vuelve inutilizable para pronóstico.

Serie Total de Viajeros: Modelado y Pronóstico

Se modeló la serie mensual Total (Turista + Excursionista) con ARIMA estacional, Holt-Winters, suavizamiento exponencial simple, seasonal naive y Prophet, evaluando cada modelo sobre los 63 meses del conjunto de prueba (2021-04 a 2026-06). El nivel promedio fue de 214,218 viajeros/mes en entrenamiento y 241,617 viajeros/mes en prueba.

***Figura 7**. Descomposición de la serie Total (tendencia, estacionalidad y residuo)*



La descomposición confirma tendencia y estacionalidad claras, con una particularidad importante, la amplitud del ciclo estacional crece junto con el nivel de la serie (correlación de 0.90 entre el nivel medio anual y su desviación estándar, excluyendo la pandemia). Un modelo aditivo simple subestimaría la variabilidad en los años de mayor volumen, así que se usó una descomposición multiplicativa y se trabajó en escala logarítmica antes de ajustar los modelos ARIMA. El componente residual se dispara en 2020, confirmando que la pandemia es un evento atípico que ningún modelo puede explicar por sí solo.

En escala logarítmica, la serie no es estacionaria en el nivel (prueba ADF, p=0.12); se logra estacionariedad aplicando una diferenciación regular y una estacional de periodo 12 (ADF, p<0.001), el mismo orden que finalmente usa el modelo ARIMA, cuyos residuos, todavía conservan algo de autocorrelación según la prueba de Ljung-Box.

***Figura 8**. Pronóstico sobre el conjunto de prueba, serie Total*



Ningún modelo pronostica con precisión el conjunto de prueba completo, porque este horizonte de 63 meses incluye dos rupturas que el entrenamiento (hasta marzo de 2021)

no pudo observar: la recuperación post pandemia y el cambio de metodología de 2022–2023. Lo relevante es el desempeño relativo entre modelos. Prophet obtiene el menor error (MAE de 132,304 y RMSE de 139,549 viajeros/mes, equivalente a un 54.8% del nivel promedio de prueba), seguido de cerca por Holt-Winters. El ARIMA seleccionado por AIC queda último, incluso por debajo del benchmark ingenuo estacional. Esto sugiere que, ante rupturas estructurales, los modelos con componentes de tendencia flexible generalizan mejor que un ARIMA ajustado solo a la dinámica prepandemia.

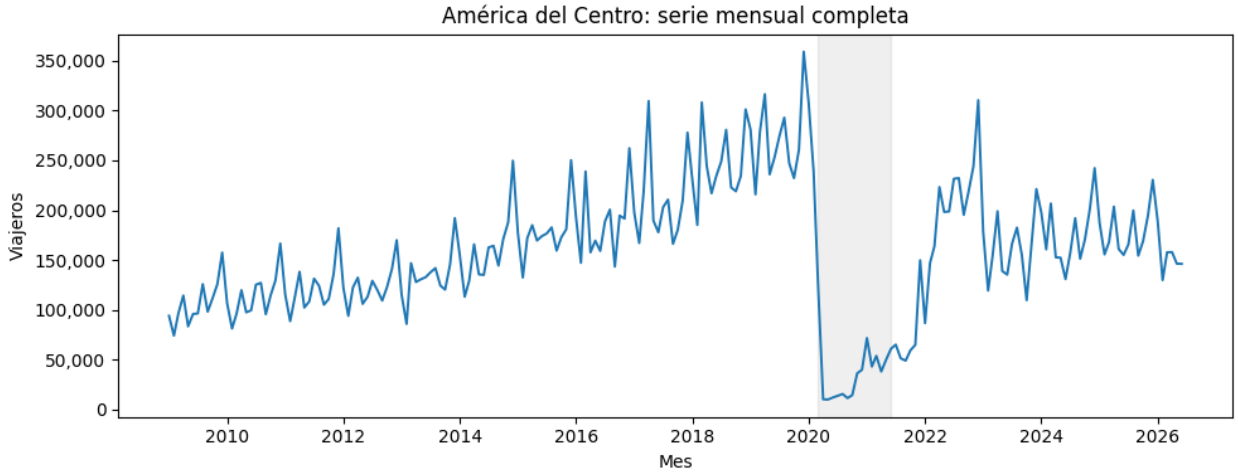
Modelo	MAE	RMSE
Prophet	132,304	139,549
Holt-Winters	134,375	146,606
Suavizamiento exp. Simple	165,373	180,598
Seasonal Naive	207,322	219,664
ARIMA$(1,1,0) \times (1,1,0,12)$	226,659	243,072

Regiones Geográficas: América del Centro, América del Norte y Europa

De las tres regiones seleccionadas (las tres con mayor volumen acumulado), se presenta el detalle completo de América del Centro por ser la de mayor peso, y se resumen los resultados de América del Norte y Europa al final de la sección.

América del Centro

***Figura 9**. Serie mensual, América del Centro (entrenamiento/prueba)*



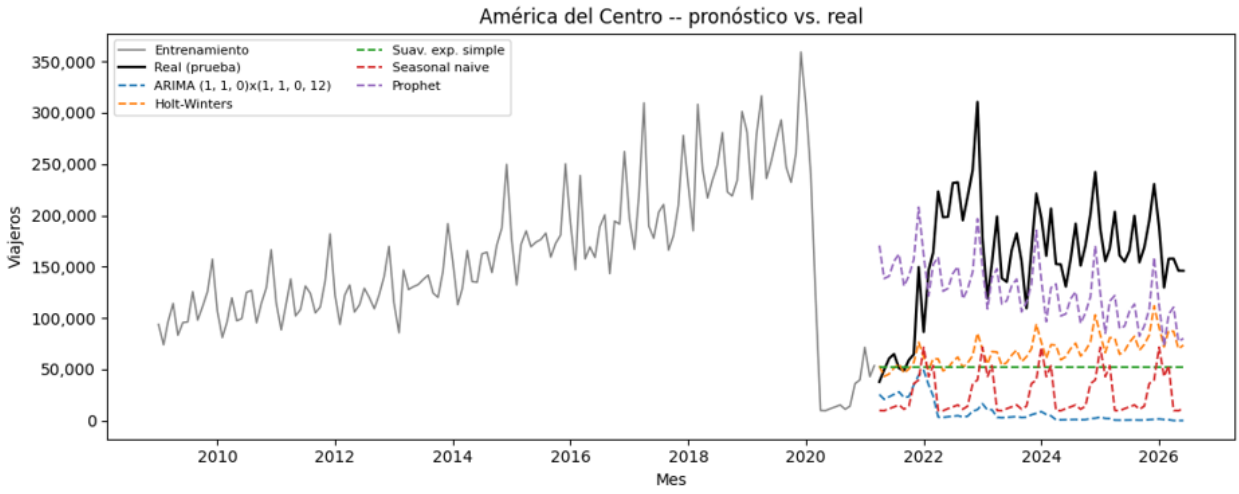
Centroamérica reproduce el mismo patrón que la serie Total (crecimiento hasta 2019, colapso en 2020 y recuperación posterior) pero a una escala mucho mayor, concentra el 71% del volumen histórico del país. Es la región que más directamente arrastra el comportamiento agregado del turismo hacia Guatemala.

***Figura 10**. Descomposición, América del Centro*



Igual que en la serie Total, la amplitud estacional de América del Centro crece con el nivel (correlación 0.85), por lo que también se usó descomposición multiplicativa y transformación logarítmica. Su fuerza de tendencia es alta (0.84), pero su fuerza estacional es la más baja de las tres regiones (0.45). Esto indica que el movimiento de los viajeros centroamericanos está menos relacionado a temporadas vacacionales específicas que a la movilidad regional cotidiana (tránsito, comercio, trabajo fronterizo). Esto es coherente, ya que gran parte de este volumen cruza por vía terrestre.

***Figura 11**. Pronóstico sobre el conjunto de prueba, América del Centro*



Sobre el conjunto de prueba, Prophet vuelve a ser el modelo con menor error (MAE de 62,485, RMSE de 67,838), muy por debajo de Holt-Winters y del resto de *benchmarks*; el ARIMA elegido por AIC queda en último lugar. El patrón se repite, en una región con una ruptura de metodología tan marcada en 2022–2023, los modelos que se adaptan a cambios de nivel superan a los que asumen una estructura fija ajustada solo con datos prepandemia.

América del Norte y Europa

Estas dos regiones muestran un comportamiento distinto al de Centroamérica; ambas requieren un orden de diferenciación distinto ($d = 0$ en América del Norte, $d = 2$ en Europa) y en ninguna gana Prophet, gana un ARIMA estacional en América del Norte y suavizamiento exponencial simple en Europa. Sus errores absolutos son mucho menores que los de América del Centro simplemente porque su volumen es menor, no porque el pronóstico sea comparativamente mejor.

Región	Mejor modelo	MAE	RMSE
América del Centro	Prophet	62,485	67,838
América del Norte	ARIMA$(1, 0, 1) \times (1, 1, 1, 12)$	31,546	35,422
Europa	Suavizamiento exp. simple	9,571	10,978

Fronteras: La Aurora, Valle Nuevo y San Cristóbal

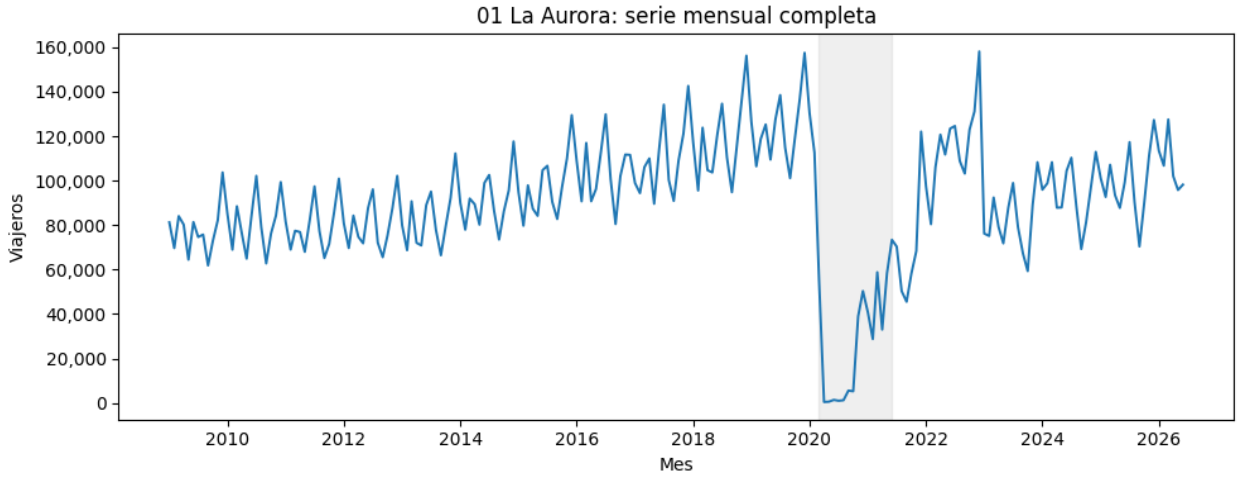
De las tres fronteras seleccionadas, se detalla La Aurora, la única de vía aérea y la de mayor volumen. Y se resumen Valle Nuevo y San Cristóbal al final de la sección.

La Aurora (aeropuerto internacional)

La Aurora concentra 19.0 millones de viajeros históricos (casi el doble que Valle Nuevo y más de cuatro veces San Cristóbal) y es la única de las tres fronteras que opera por vía aérea. Su caída durante la pandemia es también la más severa del grupo (99.6% respecto

al nivel de 2019), consistente con que los cierres de aeropuertos fueron más prolongados que los de los pasos terrestres regionales. Como principal puerta de entrada aérea del país, su comportamiento es el más sensible a decisiones externas (restricciones de vuelos, políticas de otros países) y el más relevante para la planificación de infraestructura aeroportuaria.

***Figura 12**. Serie mensual, 01 La Aurora (entrenamiento/prueba)*



La Aurora combina una fuerza de tendencia alta (0.82) con una estacionalidad moderada (0.56, la segunda más marcada de las tres fronteras) y la menor volatilidad residual del grupo (0.118), es la serie más regular en su forma, aunque eso no significo obtener un menor error de pronóstico. Igual que en el resto de las series con amplitud estacional creciente, se usó descomposición multiplicativa y transformación logarítmica.

***Figura 13**. Descomposición, 01 La Aurora*

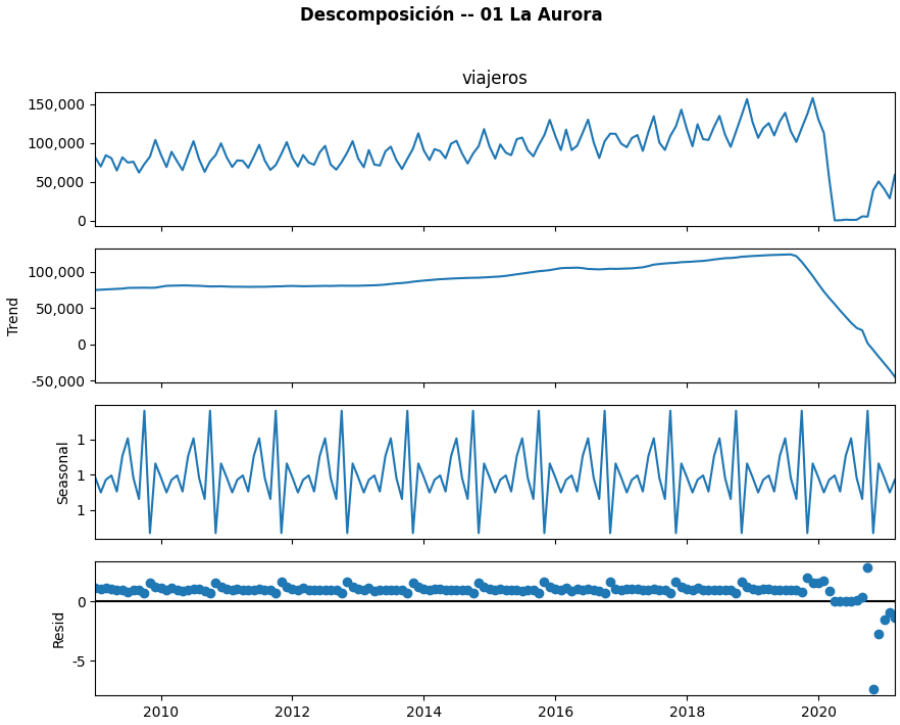
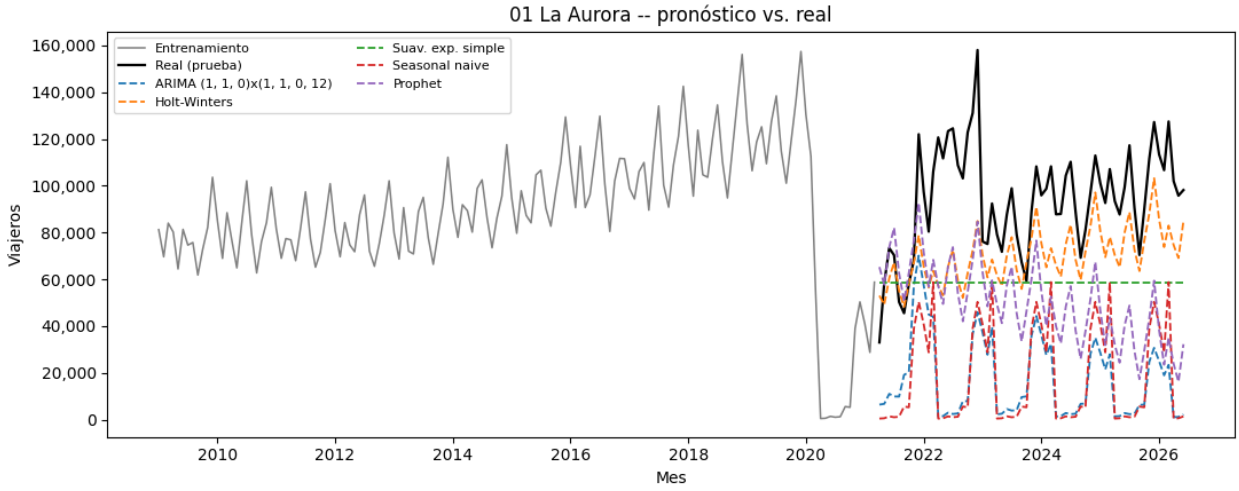


***Figura 14**. Pronóstico sobre el conjunto de prueba, 01 La Aurora*



A diferencia de la serie total y de Centroamérica, en La Aurora el modelo ganador es Holt-Winters (MAE de 25,156, RMSE de 30,237), con Prophet en tercer lugar. Esto confirma

que no hay un modelo superior para todas las series analizadas, la elección del mejor algoritmo depende de las características de cada serie.

Valle Nuevo y San Cristóbal

Estos dos pasos terrestres muestran menor fuerza estacional que La Aurora (0.37 y 0.30) y mayor volatilidad residual (0.206 y 0.270), su tráfico está más ligado a la movilidad cotidiana transfronteriza que a la temporada vacacional. En ambos gana Prophet sobre el resto de los modelos.

Frontera	Mejor modelo	MAE	RMSE
01 La Aurora	Holt-Winters	25,156	30,237
07 Valle Nuevo	Prophet	15,219	21,764
09 San Cristóbal	Prophet	7,723	10,437

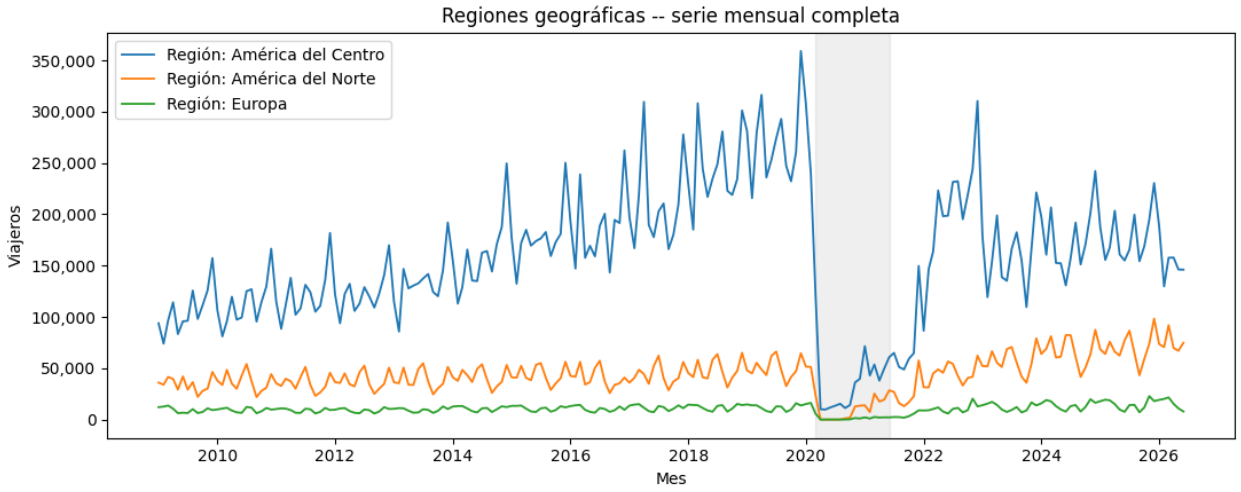
Análisis Comparativo Entre las Siete Series

Para comparar series de escalas tan distintas se calcularon, sobre el histórico completo (2009–jun. 2026) de cada serie, cuatro medidas relativas: fuerza de tendencia, fuerza estacional, volatilidad del residuo (qué tan impredecible es la serie mes a mes) y caída por la pandemia (respecto al nivel de 2019).

Serie	Fuerza tendencia	Fuerza estacional	Volatilidad residuo	Impacto pandemia
Total	0.86	0.50	0.134	97.2%
América del Centro	0.84	0.45	0.157	96.4%
América del Norte	0.88	0.70	0.126	100.0%
Europa	0.81	0.73	0.154	100.0%
01 La Aurora	0.82	0.56	0.118	99.6%
07 Valle Nuevo	0.80	0.37	0.206	99.9%
09 San Cristóbal	0.75	0.30	0.270	100.0%

Regiones geográficas

***Figura 15**. Comparación de tendencia, estacionalidad, volatilidad e impacto pandémico por región*



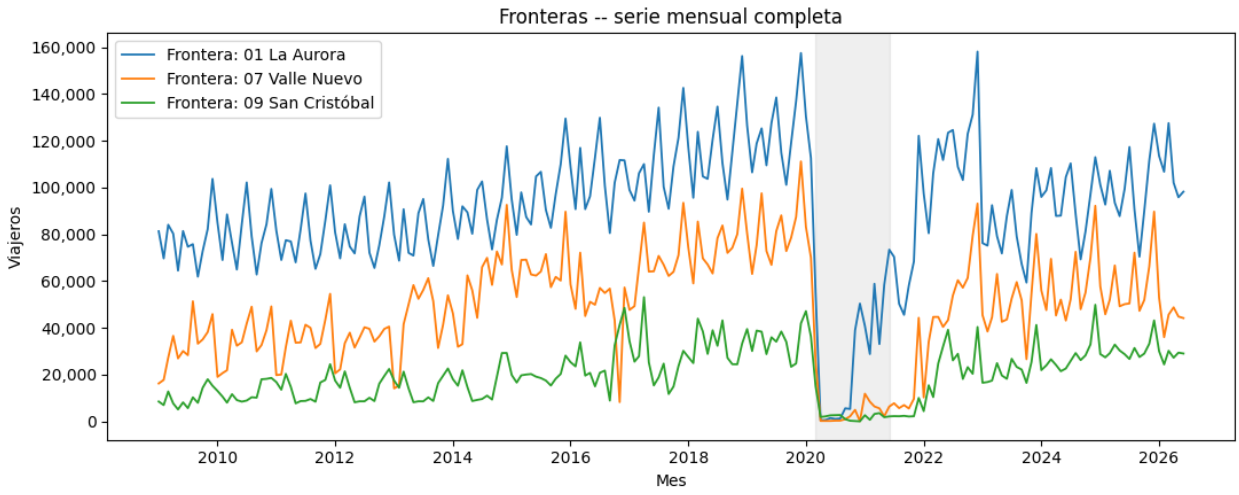
Entre las tres regiones, Europa tiene la mayor fuerza estacional (0.73) y América del Norte la mayor fuerza de tendencia (0.88) y el mayor impacto de la pandemia (caída del 100%

respecto a 2019, es decir, meses completos en cero durante el cierre total de fronteras). Centroamérica, en cambio, es la más volátil (0.157) pero la menos afectada proporcionalmente por la pandemia (96.4%). El patrón detectado indica que Europa y América del Norte dependen de la temporada alta vacacional, mientras que los viajeros de Centroamérica se caracterizan por realizar una movilidad regional constante, menos estacional y más inestable mes a mes.

Fronteras

Entre las tres fronteras, La Aurora domina tanto en estacionalidad (0.56) como en tendencia de crecimiento (0.82), mientras que San Cristóbal es la más volátil (0.270) y, junto con Valle Nuevo, la más afectada por la pandemia (caída del 100%). El contraste confirma la hipótesis del aeropuerto, al ser la única vía aérea, La Aurora tuvo un cierre más prolongado en 2020, pero fuera de la pandemia su comportamiento es más regular y predecible que el de los pasos terrestres.

***Figura 16**. Comparación de tendencia, estacionalidad, volatilidad e impacto pandémico por fronteras*



Desempeño de modelos por serie

Ninguna serie repite exactamente el mismo ganador, la elección del modelo a utilizar depende de las características de cada serie.

Serie	Mejor modelo	MAE	RMSE
Total	Prophet	132,304	139,549
América del Centro	Prophet	62,485	67,838
América del Norte	ARIMA$(1,0,1) \times (1,1,1,12)$	31,546	35,422
Europa	Suavizamiento exp. simple	9,571	10,978
01 La Aurora	Holt-Winters	25,156	30,237
07 Valle Nuevo	Prophet	15,219	21,764
09 San Cristóbal	Prophet	7,723	10,437

Conclusiones y Recomendaciones para INGUAT

Ciclo y Recuperación.

- El turismo creció sostenidamente entre 2009 y 2019 (máximo histórico de 4.13 millones de visitantes), colapsó 74% en 2020 por la pandemia y se recupera desde 2022 sin alcanzar aún el pico prepandemia (3.3 millones en 2024–2025). La estacionalidad es fuerte y estable fuera de la pandemia, con diciembre como pico y febrero como valle. Este patrón se puede utilizar para planificar la capacidad del aeropuerto con anticipación.

Concentración Geográfica y de Infraestructura.

- Centroamérica (71% del volumen histórico) y la vía terrestre (59%) dominan el flujo, con El Salvador, Estados Unidos y Honduras como principales mercados, y La Aurora, Valle Nuevo y San Cristóbal como fronteras clave. Las políticas de infraestructura o de trámite migratorio tienen mayor impacto marginal si se priorizan estos puntos en lugar de aplicar una estrategia uniforme.

Recuperación Desigual entre Segmentos.

- La caracterización comparativa de la sección de análisis comparativo confirma que no todas las series regresan al nivel de 2019 al mismo ritmo. Las campañas de promoción de INGUAT rendirían más si se dirigen a los mercados y fronteras que más tardan en recuperarse, en vez de repartirse por igual entre todos los segmentos.

Cuidado con el Cambio de Metodología de 2022–2023.

- Cualquier comparación interanual de la categoría “Viajero” (no “Turista + Excursionista”) alrededor de esos años puede sugerir una caída de turismo que en realidad es un artefacto de reclasificación de datos; INGUAT debería documentar este cambio explícitamente en sus propios reportes para evitar conclusiones erróneas.